

ELEKTROTEHNIČKI FAKULTET U BEOGRADU

KOMPJUTERSKA VIZIJA

13M051KV

Detekcija abnormalnih pojava na
mišićno-skeletnim radiogramima koristeći MURA
bazu podataka

Projektni zadatak

Autori:

Minja Vuković 2023/3053
Dragana Ninković 2023/3010

Jun 2024

Sadržaj

Abstrakt	2
Uvod	2
Baza podataka	2
DenseNet	2
Metode	3
Rezultati	5
Humerus	5
Forearm	12
Diskusija	20
Humerus	20
Forearm	20
Zaključak	22

Abstrakt

U medicini se u poslednje vreme sve više koristi mašinsko učenje kao jedan od alata za donošenje odluka. Primenu je našlo i u analizi radiograma, odnosno slika dobijenih X-zračenjem. U ovom projektu korišćena je baza podataka radiograma, MURA (eng. *Musculoskeletal radiographs*), za klasifikaciju normalnih i abnormalnih pojava kod slika nadlaktice i podlaktice. Korišćena su dva modela, pretrenirani DenseNet-169 model i korisnički definisan model. Upoređeni su rezultati performansa oba modela i dobijeno je da je DenseNet-169 u oba slučaja imao bolji performans, pri čemu su za poređenje modela korišćeni ROC (eng. *Receiver operating characteristic*) kriva, konfuziona matrica, senzitivnost, preciznost i tačnost. Takođe, uočena je razlika u performansima oba modela nad Humerus-om, koji ima izbalansirani obučavajući skup i nad podacima Forearm-a, čiji su podaci u obučavajućem skupu neizbalansirani.

Uvod

Kosti su jedan od najznačajnijih delova tela, jer predstavljaju oslonac ljudskog tela i omogućava kretanje osobe [1]. Bilo koje strukturalno ili hemijsko odstupanje od sadržaja zdrave kosti (označena kao normalna kost), predstavlja abnormalnost, tj. abnormalnu kost. Ove abnormalnosti najčešće uzrokuju fizička povreda (npr. običan prelom kostiju), genetske predispozicije (npr. autoimune bolesti) i razne infekcije (npr. osteomijolitis) [2, 3, 4]. Za ovakva istraživanja neophodna je pomoć stručnjaka, jer neke koštane abnormalnosti ne mogu da se vide veoma jednostavno. Najčešće se uzima mišljenje tri stručnjaka, pri čemu većina odlučuje o rezultatu analize radiograma. Kako u donošenju odluka prilikom posmatranja radiograma može doći do pogrešnog zaključka usled nekih faktora koje nije moguće predvideti, poput umora specijaliste ili lošeg kvaliteta slike gde se ne mogu jasno videti karakteristike pacijentove kosti, odlučuje se za korišćenje algoritama mašinskog učenja kako bi se proces odlučivanja ubrzao i bio objektivniji [2].

Baza podataka


Baza podataka korišćena u ovom projektu je MURA koja sadrži 40 561 radiogram kostiju gornjih ekstremiteta. Svaki radiogram manuelno je određen kao normalan (zdrav) ili abnormalan (kost nije zdrava) od strane radiologa iz Stanford bolnice u periodu od 2001. do 2012. godine. U prikupljanju podataka učestvovalo je 12 173 pacijenata, gde je broj studija bio 14 863. U bazi postoji 7 vrsta gornjih ekstremiteta [5, 6]:

- Lakat (eng. *Elbow*)
- Prst (eng. *Finger*)
- Šaka (eng. *Hand*)
- Nadlaktica (eng. *Humerus*)
- Podlaktica (eng. *Forearm*)
- Rame (eng. *Shoulder*)
- Zglob (eng. *Wrist*)

Zbog manjka kompjuterskih resursa (nedovoljne količine RAM-a (eng. *Random access memory*) i grafičke kartice), odlučeno je da se u ovom projektnom zadatku koriste samo podaci o nadlaktici (*Humerus*) i podlaktici (*Forearm*), jer imaju najmanje podataka u obučavajućem skupu.

DenseNet

Kao jedan od dva modela za treniranje korišćen je pretrenirani DenseNet model. Ovaj model je nastao inspirisan radovima koji su izlazili u periodu oko 2018. godine i bavili se temom produbljivanja modela. Došlo se do zaključka da je moguće korišćenje znatno dubljih modela i njihovo efikasnije treniranje, ako se dodaju konekcije blizu ulaza i izlaza sa ostalim slojevima. Iz tog razloga, ovaj model je specifičan po tome što spaja izlaz svakog sloja sa ulazima svih narednih slojeva (Sl. 1). Ova osobina pomaže u sprečavanju nestajućeg gradijenta, pomaže očuvanju znanja o naučenim obeležjima i podržava ponovo korišćenje istih. Obzirom da model ne uči više puta redundantne informacije, već samo nove koje nije već do tada naučio, broj potrebnih parametara se smanjuje. Takođe, prilikom dodatnog povećanja broja slojeva ne dolazi do preobučavanja. Ovaj model je pogodan za izvlačenje obeležja nad slikama, zato što jako dobro i sistematično izdvaja bitna obeležja ovim postupkom, pri čemu je njegov izlaz koncizan i informativan. [7]



Slika 1: Izgled arhitekture *DenseNet*. Slika preuzeta iz rada [7]

Metode

Prvi model koji je korišćen za klasifikaciju da li je došlo do preloma ili nije je pretrenirani DenseNet-169 nad skupom podataka ImageNet čija je tačna arhitektura prikazana u tabeli 1. Primetiti da se za ovaj model pod konvolucionim blokom (conv) podrazumevana tri sloja - normalizacija paketa (eng. *Batch Normalization*), ReLu (*Rectified linear unit*) i konvolucionni sloj. Uklonjen je poslednji sloj i on je dotreniran da bi se prilagodio podacima MURA skupa podataka. [7]

Tabela 1: Arhitektura DenseNet-169 modela. Deo tabele preuzet iz rada [7]

Slojevi	Izlazna veličina	Operacija
Convolution	112×112	7×7 conv, stride 2
Pooling	56×56	3×3 max pool, stride 2
Dense Block (1)	56×56	$\begin{pmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{pmatrix} \times 6$
Transition Layer (1)	56×56 28×28	1×1 conv 2×2 avg pool, stride 2
Dense Block (2)	28×28	$1 \begin{pmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{pmatrix} \times 12$
Transition Layer (2)	28×28 14×14	1×1 conv 2×2 avg pool, stride 2
Dense Block (3)	14×14	$\begin{pmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{pmatrix} \times 32$
Transition Layer (3)	14×14 7×7	1×1 conv 2×2 avg pool, stride 2
Dense Block (4)	7×7	$\begin{pmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{pmatrix} \times 32$
Classification Layer	1×1	7×7 global avg pool 1000 D fully-connected, softmax

Drugi model koji je korišćen je korisnički definisan model čija je detaljna arhitektura prikazana u tabeli 2.

Tabela 2: Arhitektura korisnički definisanog modela

Slojevi	Izlazna veličina	Operacija
Convolutional Block (1)	64×64	$\left(\begin{array}{c} 3 \times 3 \text{ Conv} \\ \text{Batch Normalization} \end{array} \right) \times 3$
Pooling (1)	64×64	3×3 avg pool, stride 2
Convolutional Block (2)	128×128	$\left(\begin{array}{c} 3 \times 3 \text{ Conv} \\ \text{Batch Normalization} \end{array} \right) \times 3$
Pooling (2)	128×128	3×3 avg pool, stride 2
Convolutional Block (3)	256×256	$\left(\begin{array}{c} 3 \times 3 \text{ Conv} \\ \text{Batch Normalization} \end{array} \right) \times 3$
Pooling (3)	256×256	3×3 avg pool, stride 2
Classification layer	1×1	7×7 global avg pool dropout, rate = 0.1 256 D fully-connected, sigmoid

U skupu podataka dostupni su samo obučavajući i validacioni skup, iz razloga što se ovaj skup podataka koristi za takmičenje [5]. Iz ovog razloga, kako bi evaluacija rezultata bila nepristrasna i objektivna, validacioni skup je podaljen na dva skupa u odnosu dva prema jedan, pri čemu je prvi korišćen kao validacioni, a drugi kao test skup. Takođe, vodilo se računa da odnos klasa u ova dva skupa bude isti kao u izvornom validacionom skupu podataka. Zbog različitih dimenzija slika, prilikom preprocesiranja, pored standardizacije, urađena je i promena dimenzija slika na dimenzije (320, 320). Zbog manjeg broja podataka, korišćena je augmentacija slika sa rotacijom do 30° i obrtanjem slika oko horizontale. Augmentacija se radi dinamički u toku obučavanja. Takođe, u toku obučavanja korišćen je metod ranog zaustavljanja kada greška počne da stagnira na validacionom skupu, kako bi se izbeglo preobučavanje. Zbog neizbalansiranosti podataka, za gubitak je korišćena otežinjena binarna entropija pri čemu su težine srazmerne broju elemenata klasa u obučavajućem skupu. Korišćena veličina paketa je 32 a broj epoha 20. Korišćen je Adam optimizator za minimizaciju greške. Kao metrike u toku treniranja korišćeni su preciznost ($\frac{TP}{TP+FP}$) i senzitivnost ($\frac{TP}{TP+FN}$), gde je TP - broj tačno klasifikovanih abnormalnosti, FP - broj loše klasifikovanih abnormalnosti, a FN broj loše klasifikovanih normalnosti. Brzina učenja inicijalno je postavljena na vrednost 0.0001 i opada 10 puta svaki put kada validaciona greška postane ravna.

Rezultati


U ovoj sekciji prikazani su osnovne informacije o skupovima podataka Humerus i Forearm, kao i rezultati klasifikacije DenseNet-169 i korisnički definisanog modela.

Humerus


Tabela 3: Podaci o obučavajućem skupu, deo tela: *Humerus*

	Obučavajući skup, deo tela: <i>Humerus</i>
Ukupan broj podataka	1272
Broj abnormalnih	599
Broj normalnih	673
Udeo abnormalnih [%]	47.09%
Udeo normalnih [%]	52.91%

Histogram velicine slike: visina, skup: Obucavajuci, deo tela: HUMERUS



Histogram velicine slike: sirina, skup: Obucavajuci, deo tela: HUMERUS



(a) Visine slika iz obučavajućeg skupa, deo tela: *Humerus* (b) Širine slika iz obučavajućeg skupam deo tela: *Humerus*

Slika 2: Histogram dimenzije slika iz obučavajućeg skupa, deo tela: *Humerus*




Slika 3: Primeri radiograma iz obučavajućeg skupa, deo tela: *Humerus*


Tabela 4: Podaci o validacionom skupu, deo tela: *Humerus*

	Validacioni skup, deo tela: <i>Humerus</i>
Ukupan broj podataka	191
Broj abnormalnih	93
Broj normalnih	98
Udeo abnormalnih [%]	48.69%
Udeo normalnih [%]	51.31%

Histogram velicine slika: visina, skup: Validacioni, deo tela: HUMERUS



Histogram velicine slika: sirina, skup: Validacioni, deo tela: HUMERUS



(a) Visine slika iz validacionog skupa, deo tela: *Humerus* (b) Širine slika iz validacionog skupam deo tela: *Humerus*

Slika 4: Histogram dimenzije slika iz validacionog skupa, deo tela: *Humerus*




Slika 5: Primeri radiograma iz validacionog skupa, deo tela: *Humerus*


Tabela 5: Podaci o testirajućem skupu, deo tela: *Humerus*

	Testirajući skup, deo tela: <i>Humerus</i>
Ukupan broj podataka	97
Broj abnormalnih	47
Broj normalnih	50
Udeo abnormalnih [%]	48.45%
Udeo normalnih [%]	51.55%

Histogram velicine slike: visina, skup: Testirajuci, deo tela: HUMERUS




Histogram velicine slike: sirina, skup: Testirajuci, deo tela: HUMERUS




(a) Visine slike iz testirajućeg skupa, deo tela: *Humerus* (b) Širine slike iz testirajućeg skupam deo tela: *Humerus*



Slika 6: Histogram dimenzije slike iz testirajućeg skupa, deo tela: *Humerus*



Slika 7: Primeri radiograma iz testirajućeg skupa, deo tela: *Humerus*





Slika 8: Gubitak kroz epohe - *DenseNet-169* model, deo tela: *Humerus*



(a) Preciznost kroz epohe - *DenseNet-169* model, deo tela: (b) Senzitivnost kroz epohe - *DenseNet-169* model, deo tela: *Humerus*

Slika 9: Parametri *DenseNet-169* modela, deo tela: *Humerus*



Tacnost modela (DenseNet): 0.8115183246073299, deo tela: XR_HUMERUS, skup: validacioni



(a) Konfuziona matrica nad validacionim skupom - (b) ROC kriva na validacionom skupu - *DenseNet-169* model, deo tela: *Humerus*


Slika 10: Konfuziona matrica i ROC kriva nad validacionim skupom - *DenseNet-169* model, deo tela: *Humerus*

Tacnost modela (DenseNet): 0.7835051546391752, deo tela: XR_HUMERUS, skup: testirajuci





(a) Konfuziona matrica nad test skupom - *DenseNet-169* (b) ROC kriva na test skupu - *DenseNet-169* model, deo tela: *Humerus*

Slika 11: Konfuziona matrica i ROC kriva nad test skupom - *DenseNet-169* model, deo tela: *Humerus*


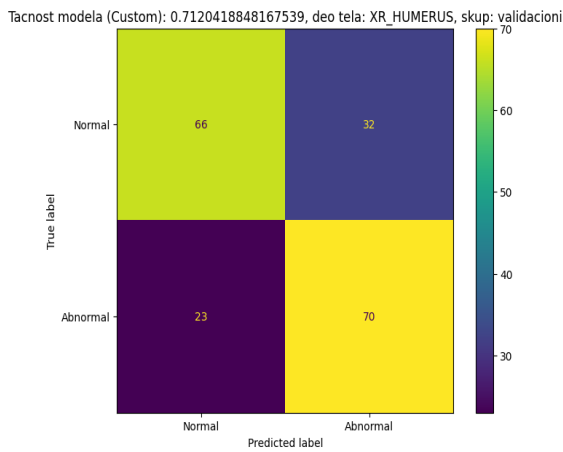


Slika 12: Gubitak kroz epohe - *Korisnički definisan* model, deo tela: *Humerus*



(a) Preciznost kroz epohe - *Korisnički definisan* model, deo (b) Senzitivnost kroz epohe - *Korisnički definisan* model, tela: *Humerus*



Slika 13: Parametri *Korisnički definisan* modela, deo tela: *Humerus*



(a) Konfuzionna matrica nad validacionim skupom - *Korisnički definisan* model, deo tela: *Humerus* (b) ROC kriva na validacionom skup - *Korisnički definisan* model, deo tela: *Humerus*

Slika 14: Konfuzionna matrica i ROC kriva nad validacionim skupom - *Korisnički definisan* model, deo tela: *Humerus*

Tacnost modela (Custom): 0.5773195876288659, deo tela: XR_HUMERUS, skup: testirajuci



(a) Konfuziona matrica nad test skupom - *Korisnički definisan model*, deo tela: *Humerus* (b) ROC kriva na test skupu - *Korisnički definisan model*, deo tela: *Humerus*

Slika 15: Konfuziona matrica i ROC kriva nad test skupom - *Korisnički definisan model*, deo tela: *Humerus*

Tabela 6: Poređenja metrika za različite modele dela tela *Humerus*


<i>Humerus</i>	DenseNet-169	Korisnički definisan
Preciznost	0.86	0.56
Senzitivnost	0.66	0.59

Forearm


Tabela 7: Podaci o obučavajućem skupu, deo tela: *Forearm*

	Obučavajući skup, deo tela: <i>Forearm</i>
Ukupan broj podataka	1825
Broj abnormalnih	661
Broj normalnih	1164
Udeo abnormalnih [%]	36.22%
Udeo normalnih [%]	63.78%

Histogram velicine slika: visina, skup: Obucavajuci, deo tela: FOREARM




Histogram velicine slika: sirina, skup: Obucavajuci, deo tela: FOREARM



(a) Visine slika iz obučavajućeg skupa, deo tela: *Forearm* (b) Širine slika iz obučavajućeg skupam deo tela: *Forearm*

Slika 16: Histogram dimenzije slika iz obučavajućeg skupa, deo tela: *Forearm*




Slika 17: Primeri radiograma iz obučavajućeg skupa, deo tela: *Forearm*


Tabela 8: Podaci o validacionom skupu, deo tela: *Forearm*

	Validacioni skup, deo tela: <i>Forearm</i>
Ukupan broj podataka	199
Broj abnormalnih	100
Broj normalnih	99
Udeo abnormalnih [%]	50.25%
Udeo normalnih [%]	49.75%

Histogram velicine slika: visina, skup: Validacioni, deo tela: FOREARM




Histogram velicine slika: sirina, skup: Validacioni, deo tela: FOREARM



(a) Visine slika iz validacionog skupa, deo tela: *Forearm* (b) Širine slika iz validacionog skupam deo tela: *Forearm*

Slika 18: Histogram dimenzije slika iz validacionog skupa, deo tela: *Forearm*




Slika 19: Primeri radiograma iz testirajućeg skupa, deo tela: *Forearm*


Tabela 9: Podaci o testirajućem skupu, deo tela: *Forearm*

	Testirajući skup, deo tela: <i>Forearm</i>
Ukupan broj podataka	102
Broj abnormalnih	51
Broj normalnih	51
Udeo abnormalnih [%]	50.00%
Udeo normalnih [%]	50.00%

Histogram velicine slika: visina, skup: Testirajuci, deo tela: FOREARM




Histogram velicine slika: sirina, skup: Testirajuci, deo tela: FOREARM



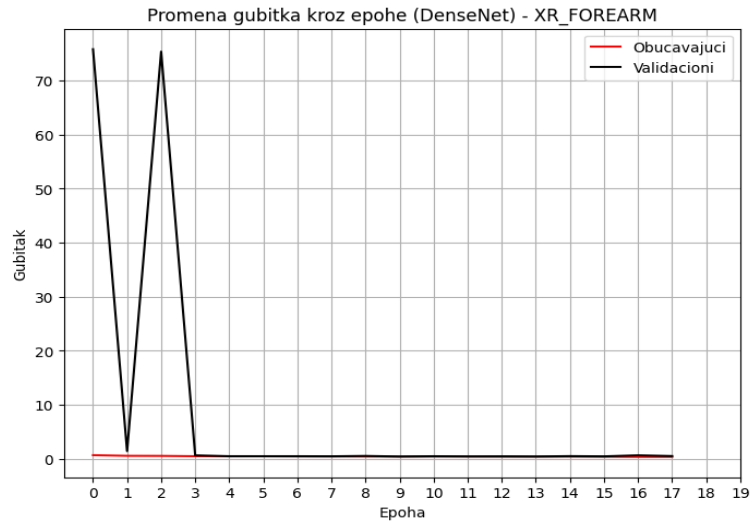
(a) Visine slika iz testirajućeg skupa, deo tela: *Forearm*

(b) Širine slika iz testirajućeg skupam deo tela: *Forearm*



Slika 20: Histogram dimenzije slika iz testirajućeg skupa, deo tela: *Forearm*



Slika 21: Primeri radiograma iz testirajućeg skupa, deo tela: *Forearm*





Slika 22: Gubitak kroz epohe - *DenseNet-169* model, deo tela: *Forearm*



(a) Preciznost kroz epohe - *DenseNet-169* model, deo tela: *Forearm* (b) Senzitivnost kroz epohe - *DenseNet-169* model, deo tela: *Forearm*

Slika 23: Parametri *DenseNet-169* modela, deo tela: *Forearm*



Tacnost modela (DenseNet): 0.7386934673366834, deo tela: XR_FOREARM, skup: validacioni



(a) Konfuziona matrica nad validacionim skupom - (b) ROC kriva na validacionom skupu - *DenseNet-169* model, deo tela: *Forearm*


Slika 24: Konfuziona matrica i ROC kriva nad validacionim skupom - *DenseNet-169* model, deo tela: *Forearm*

Tacnost modela (DenseNet): 0.7745098039215687, deo tela: XR_FOREARM, skup: testirajuci





(a) Konfuziona matrica nad testirajućim skupom - (b) ROC kriva na testirajućem skupu - *DenseNet-169* model, deo tela: *Forearm*

Slika 25: Konfuziona matrica i ROC kriva nad testirajućim skupom - *DenseNet-169* model, deo tela: *Forearm*





Slika 26: Gubitak kroz epohe - *Korisnicki definisan* model, deo tela: *Forearm*



(a) Preciznost kroz epohe - *Korisnicki definisan* model, deo (b) Senzitivnost kroz epohe - *Korisnicki definisan* model, tela: *Forearm*

Slika 27: Parametri *korisnicki definisanog* modela, deo tela: *Forearm*

Tacnost modela (Korisnički definisan): 0.542713567839196, deo tela: XR_FOREARM, skup: validacioni





(a) Konfuziona matrica nad validacionim skupom - *Korisnički definisan* model, deo tela: *Forearm*

(b) ROC kriva nad validacionim skupom - *Korisnički definisan* model, deo tela: *Forearm*

Slika 28: Konfuziona matrica i ROC kriva nad validacionim skupom - *Korisnički definisan* model, deo tela: *Forearm*

Tacnost modela (Korisnički definisan): 0.5294117647058824, deo tela: XR_FOREARM, skup: testirajući



(a) Konfuziona matrica nad testirajućim skupom - *Korisnički definisan* model, deo tela: *Forearm*

(b) ROC kriva nad testirajućim skupom - *Korisnički definisan* model, deo tela: *Forearm*

Slika 29: Konfuziona matrica i ROC kriva nad testirajućim skupom - *Korisnički definisan* model, deo tela: *Forearm*

Tabela 10: Poređenja metrika za različite modele dela tela *Forearm*

<i>Forearm</i>	DenseNet-169	Korisnički definisan
Preciznost	0.83	0.52
Senzitivnost	0.69	0.75

Diskusija

U ovom poglavlju komentarisani su grafici i tabele dobijene za Humerus i Forearm, koji su prikazani u sekciji Rezultati.

Humerus

U tabelama 3,4 i 5 prikazane su statistike za obučavajući, validacioni i test skup. Može se primetiti da sva tri skupa imaju skoro identičan procenat pozitivnih i negativnih primera i da su sva tri skoro u potpunosti izbalansirana. Na slikama 2b i 4b prikazani su histogrami širina slika, a na slikama 6a i 4a prikazani su histogrami visina slika, pri čemu su visina i dužina izražene u broju piksela. Može se primetiti da slike imaju razne dužine i visine, pri čemu ova dva histograma čak nemaju isti izgled, što znači da slike nisu kvadratnog oblika, zbog čega je prilikom pretprocesiranja histogram uniformisan promenom veličine slika na dimenzije (320, 320, 3). Na slikama 3, 5 i 7 su prikazani slučajno izabrani primeri slika iz obučavajućeg, validacionog i test skupa, pri čemu je označeno kojoj od klasa pripadaju.

Prvo se posmatraju rezultati dobijeni za DenseNet model. Na grafiku 8 prikazana je promena gubitka kroz epohe, gde se može videti da vremenom distanca između obučavajuće i validacione krive postaje sve manja i greška značajno pada, što potvrđuje uspešno učenje modela. Kao što je već rečeno, kao metrike u toku treniranja korišćene su preciznost i senzitivnost. Promena ovih metrika u toku treniranja kroz epohe prikazana je na graficima 9a i 9b. Može se primetiti da obe metrike rastu u toku vremena što znači da model ne prioretizuje ni jednu od klasa i uspeva da ih nauči obe podjednako. Na slikama 10a i 11a prikazane su konfuzione matrice validacionog i testirajućeg skupa koje potvrđuju da je model naučio obe klase ali i da klasifikuje mnogo bolje klase zdravih pacijenata. Takođe, nad oba skupa model daje relativno visoke tačnosti. Na slikama 14b i 15b vidi se da je AUC oko 0.7 i da su krive dovoljno dobre.

Nakon toga, posmatra se korisnički definisan model. Na slikama 14a i 15a prikazane su konfuzione matrice validacionog i testirajućeg skupa. Na validacionom skupu slični su rezultati kao za DenseNet model samo što može se primetiti da su se dosta pogoršale performanse nad normalnim primerima u odnosu na DenseNet, dok su performanse za abnormalne primere malo poboljšale, ali su i dalje dosta loše. Ipak, ako se posmatra test skup, vidi se da su skoro sva četiri polja konfuzione matrice jednaka što znači da uprkos malom gubitku, model skoro da slučajno pokušava da pogodi klase bez da ih je zapravo naučio. Na slikama 14b i 15b prikazane su ROC krive i vidi se da su više spuštene ka dijagonali u odnosu na DenseNet rezultate, što potvrđuje prethodnu tvrdnju. Posmatrajući tabelu 6 može se primetiti da su obe metrike bolje za DenseNet model, tj. da je bolji performans kada se koristi pretrenirani model u odnosu na korisnički definisan model.

Forearm

Posmatrajući tabelu 7 može se primetiti da su podaci u obučavajućem skupu nebalansirani, dok je drugačiji slučaj kod podataka u validacionom (Tabela 8) i u testirajućem skupu (Tabela 9). Takođe, može se primetiti da su veličine radiograma različite. Najveći broj slika ima visinu od 500 piksela (Tabela 16a, 18a i 20a), dok vrednosti širina slika više variraju u odnosu na vrednosti visina radiograma iz jednog skupa. Tako se može primetiti da najveći broj radiograma iz obučavajućeg skupa ima širinu oko 420 piksela, u validacionom skupu širina u najvećem broju slučajeva je 500 piksela, dok u testirajućem širina radiograma je najčešće oko 430 piksela. Primeri radiograma podlaktice pacijenata iz sva tri skupa označenih kao normalni, odnosno abnormalni, prikazani su na slikama 17, 19 i 21.

Na slici 22 može se primetiti da na početku treniranja modelom DenseNet, gubitak ima nagli pad i skok, što se može objasniti činjenicom da se brzina učenja (eng. *Learning Rate*) menja tokom epoha. Nakon treće epohe gubici na obučavajućem i na validacionom skupu su se izjednačili i vrednosti su bliske nuli. Takođe, primećeno je da je obučavanje prestalo u 17. epohi, jer je primenjen metod ranog zaustavljanja. Vrednosti preciznosti i senzitivnosti (Sl. 23a i 23b) tokom obučavanja rastu, što je i očekivano. Iako je očekivano da je tačnost na validacionom skupu (Sl. 24a) veća nego na testirajućem (Sl. 25a), može se desiti i obrnut slučaj, a razlog tome može biti slučajan odabir podataka koji su pokazali neznatno bolju tačnost na testirajućem skupu. U oba slučaja tačnost je zadovoljavajuća, što se može videti i sa slika 24b i 25b.

U slučaju kada su podaci obučavani korisnički definisanim modelom, gubitak tokom epoha (Sl. 26) nema naglih promena, kao što je slučaj na slici 22. Do prestanka obučavanja gubitak na validacionom skupu nije stagnirao

i postao blizak vrednosti 0. Iako preciznost (Sl. 27a) i senzitivnost (Sl. 27b) tokom vremena rastu, te vrednosti ne stagniraju, pa uzimajući sve činjenice u obzir, ne očekuje se relativno velika tačnost od korisnički definisanog modela. U ovom slučaju tačnost nad validacionim skupom (Sl. 28a) je neznatno veća od tačnosti nad testirajućim skupom (Sl. 29a), što je i očekivano. Sa slika 28b i 29b može se primetiti da su ROC krive bliske dijagonali, tj. da model ne može uspešno klasifikovati između normalnih i abnormalnih radiograma, već slučajno nagađa. I u validacionom (Sl. 28a) i u testirajućem skupu (Sl. 28a) model veći broj slika klasifikuje kao abnormalne, nego kao normalne. Razlog tome može biti da je model previše jednostavan za ovaj skup podataka. U tabeli 10 prikazane su vrednosti metrika preciznost i senzitivnost. Može se primetiti da je manja razlika između preciznosti i senzitivnosti kod DenseNet modela, nego kod korisnički definisanog modela i da u proseku bolje klasifikuje podatke.

Zaključak

Iz analize rezultata može se zaključiti da model DenseNet daje bolje rezultate i u slučaju klasifikacije nad Humerus i nad Forearm podacima. Ovaj rezultat se objašnjava time da je DenseNet treniran nad velikim skupom podataka i da je dimenzija ulaza u sigmoid u slučaju DenseNet modela reda 1000, a da je ulaz u sigmoid kod korisnički definisanog modela manji, odnosno 256.

Iako se pretpostavljalo da će se nad podacima dela tela Forearm dobiti lošiji rezultati, jer obučavajući skup nije izbalansiran, ipak daje bolje rezultate od obučavanja nad slikama Humerus. Razlog tome može biti da je obučavajući skup Forearm-a teži nego obučavajući skup Humerus-a, pa se kao posledica toga trenirao nad težim, a testirao nad lakšim skupom podataka. U slučaju korisnički definisanog modela, može se primetiti da je nad podacima Humerus naučio podjednako obe klase, dok nad podacima Forearm, zbog neizbalansiranosti obučavajućeg skupa, nije uspeo da podjednako dobro nauči klase normalnih i abnormalnih slika.

Literatura

- [1] Branch NSC and O. What Is Bone? [Internet]. National Institute of Arthritis and Musculoskeletal and Skin Diseases. 2023. Dostupno na: <https://www.niams.nih.gov/health-topics/what-bone>
- [2] Barhoom A, Rasheed M, Al-Hiealy J, Abu-Naser S. BONE ABNORMALITIES DETECTION AND CLASSIFICATION USING DEEP LEARNING-VGG16 ALGORITHM. Journal of Theoretical and Applied Information Technology [Internet]. 2022 [citirano 2024. Maj 22];31:20. Dostupno na: <https://www.jatit.org/volumes/Vol1100No20/29Vol1100No20.pdf>
- [3] Santhakumar S. Bone diseases: Types, symptoms, and treatments [Internet]. www.medicalnewstoday.com. 2022. Dostupno na: <https://www.medicalnewstoday.com/articles/bone-diseases#conditions>
- [4] How Is Osteomyelitis Cured? [Internet]. Cleveland Clinic. Dostupno na: <https://my.clevelandclinic.org/health/diseases/osteomyelitis-bone-infection>
- [5] Rajpurkar P, Irvin J, Bagul A, Ding D, Duan T, Mehta H, et al. MURA: Large Dataset for Abnormality Detection in Musculoskeletal Radiographs [Internet]. Dostupno na: <https://arxiv.org/pdf/1712.06957>
- [6] MURA Dataset: Towards Radiologist-Level Abnormality Detection in Musculoskeletal Radiographs [Internet]. Github.io. 2018. Dostupno na: <https://stanfordmlgroup.github.io/competitions/mura/>
- [7] Huang G, Liu Z, Weinberger, Kilian Q. Densely Connected Convolutional Networks [Internet]. arXiv.org. 2016. Dostupno na: <https://arxiv.org/abs/1608.06993>